

Inteligencia Artificial para la Predicción Automática de Parámetros Geométricos en Moldes Nanoestructurados

Agustín Ottaviano
Director: Fernando Meneses

Universidad Nacional de Córdoba

26 de marzo de 2026

- 1 Motivación
- 2 Generación del Dataset Simulado
- 3 Normalización de las labels
- 4 Pipeline de Entrenamiento

El problema: Medir la geometría de los poros

Material: AAO


Membrana nanoestructurada con poros cilíndricos organizados en red hexagonal. Sus propiedades ópticas y mecánicas dependen de la geometría de los poros.

Objetivo

Predecir automáticamente los parámetros geométricos de una imagen SEM.


5 variables objetivo

R, σ_R	Radio promedio y dispersión [px]
DCC, σ_{DCC}	Distancia centro a centro [px]
P	Porosidad (%)



Generación del Dataset Simulado

Se generaron **20 000 imágenes** de 300×300 px. Cada imagen genera una fila en el CSV con variables: R , σ_R , DCC , σ_{DCC} , P .



Parámetros aleatorios por imagen

- **Radio** $r \in [10, 30]$ px: tamaño promedio de los poros en la imagen simulada.
- **Distancia centro a centro** $dcc \in [2,5r, 4,5r]$: garantiza que no se solapen y cubre distintas densidades de poros.
- **Desorden** en r y dcc (hasta 10 %).
- **Rotación** $\theta \in [0^\circ, 360^\circ]$.
- **Brillo** $B \in [-40, 40]$: suma una constante a cada píxel, aclarando u oscureciendo la imagen.
- **Contraste** $C \in [0,6, 1,4]$: escala el rango de grises; $C < 1$ reduce la diferencia entre poros y fondo, $C > 1$ la aumenta.
- **Ruido**: perturbación aleatoria pixel a pixel que simula el ruido electrónico del detector del microscopio.

Normalización de las Labels

Por qué normalizar

Las variables tienen escalas muy distintas: $R \sim 20$ px pero $P \sim 0,3$. Sin normalizar, las variables grandes dominan el MAE y el modelo aprende mal.

StandardScaler

Técnica que transforma las variables:

$$x_{\text{norm}} = \frac{x - \mu}{\sigma}$$

donde μ y σ son la media y la desviación estándar de cada variable, respectivamente.

Resultado: media 0 y desv. est. 1.

Transformación Inversa

Despejar x de la ecuación:

$$x = x_{\text{norm}} \cdot \sigma + \mu$$

Importante: Los valores de μ y σ se guardan.

Flujo del proceso

- 1 CSV Original con 5 variables
- 2 Aplicar StandardScaler
- 3 Guardar scaler
- 4 Labels listas para entrenar
- 5 Entrenar la red neuronal
- 6 Evaluar la red neuronal y usar Scaler Inverso para obtener MAPE

Transformación de Imágenes

Valores originales

Las imágenes SEM vienen con píxeles en rango $[0, 255]$.

Normalización de píxeles

Se transforman a uno de estos rangos:

- Rango $[0, 1]$: dividir por 255
- Rango $[-1, 1]$: dividir por 127.5 y restar 1
- Mantener $[0, 255]$: sin transformación

¿Por qué?

Facilita la convergencia del modelo. Además, algunas arquitecturas de Transfer Learning (como VGG o ResNet) fueron entrenadas con imágenes en $[-1, 1]$ o $[0, 1]$, por lo que requieren esa misma normalización para funcionar correctamente.

División del Dataset

Partición de las 20 000 imágenes

- **Train Set** (40 % $\approx$ 8 000): el modelo ajusta sus pesos sobre este conjunto en cada época de entrenamiento.
- **Validation Set** (20 % $\approx$ 4 000): se evalúa al final de cada época para monitorear el aprendizaje sin usarlo para ajustar pesos.
- **Test Set** (40 % $\approx$ 8 000): se usa una única vez al final para reportar el desempeño real del modelo.



Entrenamiento

- **Batch size** 32: en vez de actualizar los pesos de la red con una imagen a la vez, se acumulan 32 imágenes y se actualiza una sola vez. Reduce el ruido del aprendizaje y acelera el entrenamiento.
- **Épocas**: máximo 150, pero con early stopping: si la pérdida en Validation Set no mejora durante 20 épocas consecutivas, el entrenamiento se detiene antes para evitar sobreajuste y ahorrar tiempo.

Entrenamiento del Modelo

Arquitectura

Dos opciones:

- **CNN Completa:** Arquitectura de una red convolucional entrenada desde cero.
- **Transfer Learning:** Se utilizan capas de un modelo preentrenado y se le agregan capas convolucionales al final que son entrenadas acordes a lo que se necesita predecir.

Datos de entrada

- Imágenes: transformadas a $[0, 1]$, $[-1, 1]$ o $[0, 255]$
- Labels: normalizados con StandardScaler

Obtención del MAPE en Test Set

Paso 1: Predicciones

El modelo entrenado realiza predicciones en Test Set:

$$\text{Modelo}(x_{\text{img}}) = (\hat{R}_{\text{norm}}, \hat{\sigma}_{R,\text{norm}}, \hat{DCC}_{\text{norm}}, \hat{\sigma}_{DCC,\text{norm}}, \hat{P}_{\text{norm}})$$

Paso 2: Scaler Inverso

Desnormalizamos las predicciones normalizadas aplicando la transformación inversa:

$$(\hat{R}, \hat{\sigma}_R, \hat{DCC}, \hat{\sigma}_{DCC}, \hat{P}) = \text{scaler.inverse_transform}(\hat{R}_{\text{norm}}, \hat{\sigma}_{R,\text{norm}}, \dots)$$

Paso 3: Calcular MAPE

Calculamos MAPE para cada una de las variables en el Test Set:

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \%$$

donde y_i son los labels reales del Test Set y $\hat{y}_i$ las predicciones.

Evaluación en Dataset Externo Real

Dataset externo

Se utilizaron **24 imágenes SEM reales** (no simuladas) con sus parámetros geométricos medidos manualmente para evaluar la generalización del modelo.

Objetivo

Verificar si el modelo entrenado con imágenes simuladas es capaz de predecir correctamente los parámetros de imágenes reales.

Métrica

MAPE sobre R , DCC y P en espacio real (unidades originales).




Imagen SEM real con franja de parámetros

Evaluación en Dataset Externo Real: Pipeline

Desafíos de las imágenes SEM reales

- 1 Las imágenes tienen resolución mas grande a la utilizada en el entrenamiento.
- 2 Las imágenes suelen incluir una franja impresa con parámetros del microscopio (escala, voltaje, etc.).

Solución: recorte por esquina

Para cada imagen se seleccionó una esquina de 300×300 px libre de la franja de parámetros del microscopio.

Pipeline de evaluación

- 1 Leer labels en espacio real (sin estandarizar)
- 2 Recortar cada imagen a 300×300 px sin franja de parámetros
- 3 Normalizar píxeles igual que en el entrenamiento
- 4 Obtener predicciones y convertirlas al espacio real
- 5 Calcular MAPE sobre R , DCC , P

Nota

Los parámetros reales de las imágenes SEM están en unidades originales. Las predicciones del modelo se desnormalizan antes de comparar, para que ambos estén en el mismo espacio.


Evaluación en Dataset Externo Real: Resultados

MAPE — 24 imágenes SEM

Variable	MAPE
Radio R	11,00 %
Distancia DCC	11,53 %
Porosidad P	20,51 %

Conclusión

El modelo es aceptable: la mayoría de las imágenes presentan errores por debajo del 20 %.



¡Gracias!